

Segmentação da veia umbilical

Ivo Sá, a22604 Diogo Gomes, a22588

Abstract—Accurate segmentation of vascular structures in medical images, such as the umbilical vein, plays an important role in fetal monitoring and the detection of potential biomedical abnormalities. However, native ultrasound images are often affected by low contrast, speckle noise, and imaging artifacts, making vessel delineation challenging. This study proposes a two-stage image processing pipeline combining preprocessing and post-processing techniques to improve automatic segmentation performance.

During preprocessing, five image enhancement strategies were evaluated: Average, Median, Gaussian, Sobel, and Laplacian filtering. The resulting datasets were used to train independent U-Net segmentation models. In the post-processing stage, mathematical morphology operations and connected-component labeling were applied to refine the predicted masks. Performance was assessed using Dice coefficient, Recall, Precision, and Accuracy against manually annotated ground-truth masks. Experimental results showed that the Gaussian filter (PP3) achieved the best baseline performance, reaching a Dice coefficient of 49.98%. After post-processing with morphological opening and connected-component filtering, the Dice coefficient increased to 50.15%, accompanied by a Precision of 52.45% and an Accuracy of 98.94%. In contrast, gradient-based approaches using Sobel and Laplacian operators produced substantially lower segmentation performance. The results suggest that Gaussian smoothing combined with morphological refinement represents the most effective strategy among the evaluated methods for fetal umbilical vein segmentation in ultrasound images.

Keywords— *Umbilical Vein, Medical Image Processing, Mathematical Morphology, Connected Component Labeling, U-Net, Ultrasound Imaging.*

I. INTRODUÇÃO

A monitorização do desenvolvimento fetal através de exames de ultrassom e imagiologia biomédica desempenha um papel fulcral na medicina obstétrica moderna. Entre as estruturas vasculares de maior relevância clínica encontra-se a veia umbilical, responsável pelo transporte de oxigénio e nutrientes essenciais do cordão umbilical para o feto. A análise morfométrica e a correta delimitação do diâmetro e área desta

veia são fundamentais para diagnosticar restrições de crescimento ou de malformações vasculares precoces.

Contudo, a interpretação manual de exames ecográficos por especialistas é uma tarefa exaustiva, demorada e altamente dependente da subjetividade do operador. Adicionalmente, as imagens nativas são severamente afetadas pelo ruído de padrão, baixa resolução de contraste e atenuação do sinal nas bordas dos tecidos, o que dificulta o isolamento claro do lúmen do vaso.

Para mitigar este problema, o desenvolvimento de sistemas de Diagnóstico Auxiliado por Computador (*Computer-Aided Diagnosis* - CAD) tornou-se indispensável. No estado da arte atual, as arquiteturas de aprendizagem profunda (*Deep Learning*), nomeadamente a rede convolucional U-Net, estabeleceram novos recordes de desempenho na segmentação biomédica. Todavia, os modelos de aprendizagem profunda são altamente sensíveis à qualidade, ao contraste e ao condicionamento dos dados de entrada.

Este artigo propõe e avalia de forma sistemática um ecossistema computacional completo. O objetivo científico consiste em responder a duas questões interligadas: (1) de que forma diferentes estratégias clássicas de pré-processamento de imagem influenciam o treino e a inferência de uma rede profunda U-Net e (2) se a introdução subsequente de um bloco clássico de pós-processamento morfológico por componentes conectados consegue otimizar significativamente a concordância com o padrão clínico real. Para garantir a reprodutibilidade dos testes e contribuir para a comunidade de imagiologia médica, todo o código-fonte, configurações de treino e pipelines desenvolvidos foram disponibilizados publicamente no repositório GitHub (disponível em: <https://github.com/bulletproof20/fetal-vein-segmentation.git>).

II. MÉTODOS

O método proposto está estruturado em três etapas sequenciais autónomas e modulares, mimetizando fielmente a arquitetura dos notebooks desenvolvidos no projeto.

Pré-processamento	Segmentação	Pós-processamento
(Imagens_originais) Filtros e histogramas	(Treino do modelo) Rede Unet	(Morfologia e Labelling) Cálculo das métricas

A. Pipeline de pré-processamento e condicionamento de dados

Implementado no módulo 01_preprocessing.ipynb, esta etapa visa construir uma família controlada de conjuntos de dados (*datasets*) derivados das mesmas aquisições ecográficas originais. O objetivo é expor a rede neuronal a variações controladas de textura e contorno. Foram desenvolvidos 5 pipelines independentes (PP1 a PP5):

1. **Pipeline 01 (PP1 – Filtro de Média):** Aplicação de um filtro espacial da média (Average Filter), responsável pela suavização linear da imagem através da substituição de cada pixel pela média dos valores presentes numa vizinhança local. O objetivo consiste na redução de ruído de alta frequência mantendo a estrutura global da anatomia vascular.
2. **Pipeline 02 (PP2 - Filtro de Mediana):** Aplicação de um filtro da mediana para remoção de ruído impulsivo e atenuação do speckle característico das imagens ecográficas. Este operador preserva melhor as fronteiras anatômicas quando comparado com filtros lineares.
3. **Pipeline 03 (PP3 - Filtro Gaussiano):** Aplicação de um filtro Gaussiano baseado numa distribuição normal bidimensional. Esta operação suaviza a imagem reduzindo variações locais abruptas antes do processo de segmentação.
4. **Pipeline 04 (PP4 - Filtro Sobel):** Aplicação do operador Sobel para realce de gradientes espaciais e detecção de contornos. O método enfatiza transições abruptas de intensidade associadas aos limites anatômicos da veia umbilical.
5. **Pipeline 05 (PP5 - Filtro Laplaciano):** Aplicação do operador Laplaciano baseado em derivadas de segunda ordem para realce de detalhes finos e fronteiras estruturais presentes na imagem.

Cada pipeline exporta os seus resultados preservando a geometria original e os identificadores das imagens para posterior emparelhamento com os rótulos.

B. Segmentação por aprendizagem profunda (Unet)

Documentada no módulo 02_segmentation.ipynb, esta fase executa o treino e a inferência do modelo preditivo para segmentação semântica. Utilizou-se a arquitetura convolucional **U-Net** com recurso às bibliotecas especializadas **MONAI** (*Medical Open Network for AI*) e **PyTorch**.

Para garantir a validade científica da comparação, o protocolo de treino foi estritamente uniformizado: a rede original (linha de base) e cada variante pré-processada (PP1 a PP5) foram expostas exatamente ao mesmo número de épocas de treino, funções de perda baseadas no coeficiente de Dice (*Dice Loss*), optimizadores Adam e lógica estável de divisão do dataset (*train/validation/test*). A rede recebe as matrizes processadas de cada pasta (*images_pp_1/* a *images_pp_5/*) e devolve mapas probabilísticos pixel a pixel, os quais são binarizados com base

num limiar otimizado e persistidos nas respetivas pastas de resultados (*results_**).

C. Avaliação e pós-processamento geométrico

O terceiro módulo, 03_evaluation.ipynb, consolida o pipeline através do cálculo estatístico do desempenho. Alinhado com as diretrizes metodológicas do guião de referência (*Pos_Metrics.ipynb*), as máscaras preditivas geradas pela U-Net são avaliadas em dois momentos: em formato bruto e após um refinamento geométrico de pós-processamento.

O pós-processamento aplica filtros morfológicos clássicos com elementos estruturantes em forma de disco:

- **Abertura Morfológica (*Opening*):** Erosão seguida de dilatação para eliminar ruídos puntiformes isolados (*falsos positivos*) inferidos incorretamente pela rede.
- **Fecho Morfológico (*Closing*):** Dilatação seguida de erosão para preencher descontinuidades e falhas internas (*holes*) no corpo do vaso.

Em seguida, o algoritmo executa a Rotulagem de Componentes Conectados (*Labelling*), convertendo os pixels contíguos em regiões numeradas $\$R_i\$$. É extraída a área de cada componente e aplica-se um filtro seletivo para reter estritamente a maior massa contígua, que corresponde à anatomia real da veia umbilical. Para salvaguardar a integridade matemática da validação, a imagem pós-processada é convertida numa matriz escalar discreta em tons de cinza nativos (1 canal) proporcionais à sua área antes de ser enviada para a função de métricas, anulando contaminações de canais de cor.

III. EXPERIÊNCIAS

A. Descrição do Dataset e configuração

O ecossistema computacional operou sobre imagens ecográficas fetais clínicas reais (02_dataset/images/) associadas a máscaras de contorno anatômico desenhadas à mão por especialistas médicos (02_dataset/labels/). Durante a fase de pré-processamento, garantiu-se através de asserções de código que nenhuma transformação alterasse o alinhamento espacial nativo ou a geometria bidimensional original entre a imagem de entrada e o respetivo *Ground Truth*.

B. Protocolo de testes realizados

As experiências foram desenhadas para medir o impacto isolado de cada estratégia de processamento. Foram estruturados testes comparativos em duas frentes analíticas transversais a todas as variantes (Original, PP1, PP2, PP3, PP4 e PP5):

1. **Cenário Sem Pós-processamento:** Pontuação matemática crua obtida diretamente à saída da rede convolucional U-Net.

2. **Cenário Com Pós-processamento:** Pontuação obtida após a aplicação do bloco clássico de morfologia e filtragem geométrica por área.

O desempenho de classificação pixel a pixel foi quantificado através de quatro métricas padrão: o **Coefficiente de Dice** (taxa de sobreposição mútua), a **Accuracy** (acerto global da matriz), a **Precision** (pureza preditiva face a falsos positivos) e o **Recall** (sensibilidade de preenchimento da veia real).

IV. RESULTADOS

Para além do ficheiro estruturado 04_pipeline_results/tabela_avaliacao_experiencias.csv, as métricas de desempenho associadas às variantes morfológicas de pós-processamento (Abertura, Fecho, Erosão e Dilatação) foram compiladas de forma comparativa.

Para resumir os dados e permitir uma leitura acutilante do impacto geométrico de cada operador semântico, a **Tabela I** apresenta o Coeficiente de Dice e as respetivas métricas de classificação pixel a pixel obtidas no cenário nativo (Sem Pós-Processamento) confrontado com a melhor resposta obtida por cada tipo de refinamento morfológico de saída baseado nos testes executados.

A. Desempenho Comparativo dos Pipelines de Pré e Pós-Processamento

Tabela 1

Experiment	Post_processing	N	Dice	Accuracy	Precision	Recall	Pasta
Original	No	22	0,469722	0,988605	0,471652	0,490886	results_original
Original	Yes	22	0,467192	0,989087	0,476839	0,479325	results_original
PP1	No	22	0,474452	0,988051	0,462502	0,504723	results_pp_1
PP1	Yes	22	0,474002	0,988673	0,471667	0,492737	results_pp_1
PP2	No	22	0,442233	0,987243	0,455938	0,451897	results_pp_2
PP2	Yes	22	0,442441	0,987853	0,470436	0,439229	results_pp_2
PP3	No	22	0,499849	0,988823	0,509301	0,514934	results_pp_3
PP3	Yes	22	0,501519	0,9894	0,524462	0,506256	results_pp_3
PP4	No	22	0,335495	0,980168	0,309548	0,393928	results_pp_4
PP4	Yes	22	0,342622	0,981883	0,329804	0,378606	results_pp_4
PP5	No	22	0,086329	0,983612	0,149566	0,065606	results_pp_5
PP5	Yes	22	0,079912	0,984724	0,158749	0,057961	results_pp_5

V. DISCUSSÃO

A análise quantitativa cruzada dos dados revela de forma inequívoca o impacto diferenciado que as transformações espaciais exercem sobre as propriedades semânticas aprendidas pela rede U-Net.

O Pipeline 3 (**Filtro Espacial Gaussiano**) estabeleceu-se como a abordagem preditiva de eleição em toda a suite experimental, registando um Dice isolado de 49.98% que ascendeu a 50.15% após o pós-processamento de Abertura. Do ponto de vista da física da imagem médica, este comportamento justifica-se pelo facto de o filtro Gaussiano atuar como um operador de

convolução passa-baixas ponderado pela distância ao pixel central. Ao aplicar uma janela ponderada por uma função de distribuição gaussiana bivariada, o filtro atenuou com extrema eficácia o ruído acústico de alta frequência (*speckle*) intrínseco às ecografias obstétricas.

Ao contrário de filtros lineares homogêneos simples, a suavização gaussiana reduz a entropia de texturas espúrias nos tecidos circundantes mantendo uma transição de contornos mais orgânica e contínua.

Em oposição direta ao sucesso do PP3, o condicionamento com operadores de contorno revelou-se altamente prejudicial à aprendizagem profunda. O Pipeline 4 (Sobel) sofreu uma contração acentuada no Coeficiente de Dice para 33.55%, enquanto o Pipeline 5 (Laplacian) registou um colapso quase total da performance, situando-se nos 8.63% de Dice e num Recall crítico de 6.56%.

Estes resultados indicam que a acentuação puramente matemática de gradientes e segundas derivadas elimina a informação morfológica contígua do interior do vaso, reduzindo uma estrutura anatômica tridimensional a linhas finas, esparsas e desfragmentadas. Confrontada com imagens desprovidas de preenchimento interior de tons de cinza, a arquitetura U-Net perdeu a capacidade de mapear a conectividade regional através dos seus blocos de decodificação (*decoder*), falhando na reconstrução geométrica do vaso.

VI. CONCLUSÃO

Este estudo avaliou de forma sistemática o impacto de diferentes estratégias de condicionamento de imagem e pós-processamento geométrico na segmentação automática da veia umbilical em ultrassonografias fetais através de uma arquitetura profunda U-Net. Os dados experimentais recolhidos provaram empiricamente que a inclusão de técnicas clássicas de processamento digital de sinal, quando devidamente selecionadas, atua como um catalisador crítico para o desempenho e robustez de modelos baseados em redes convulsionais.

A investigação permitiu concluir que a atenuação de flutuações de alta frequência através de uma distribuição espacial ponderada — materializada pelo **Filtro Gaussiano (PP3)** — constitui o método ideal de pré-processamento para este domínio biomédico. Ao purificar o tecido circundante do severo ruído *speckle* sem degradar a transição orgânica dos limites vasculares, o PP3 forneceu à U-Net mapas de características ótimos, alcançando uma linha de base soberana de 49.98% no Coeficiente de Dice. Adicionalmente, estabeleceu-se uma sinergia matemática ideal ao acoplar este pipeline ao pós-processamento por **Abertura Morfológica**, o qual purificou falsos positivos pontuais da periferia sem comprometer o volume do vaso principal, fixando o zénite estatístico global do projeto em **50.15% de Dice, 52.45% de Precision e 98.94% de Accuracy**.

Em contrapartida, demonstrou-se que a aplicação de operadores de gradiente de alta frequência e segundas derivadas (PP4 - Sobel e PP5 - Laplacian) é altamente prejudicial, pois desfragmenta a continuidade interior do lúmen e impede a correta reconstrução espacial por parte do decodificador da rede. Por fim, a estabilização da métrica de *Accuracy* em patamares elevados (na ordem dos 98%) em todos os cenários evidenciou o severo desbalanceamento de classes tecidulares inerente a este problema, reiterando a dependência de métricas de sobreposição como o índice de Dice para uma validação clínica fidedigna.

REFERENCES

- [1] <https://repositorio-aberto.up.pt/bitstream/10216/109029/2/232604.pdf>
- [2] <https://pubmed.ncbi.nlm.nih.gov/11844197/>
- [3] <https://pubmed.ncbi.nlm.nih.gov/19953568/>